

实验2：Dify基础入门使用


1. 实验概述

本实验旨在通过使用 Dify 平台，帮助初学者快速掌握构建 AI 应用的全流程，涵盖从接入大模型到应用发布的全过程。Dify 是一款开源的大语言模型（LLM）应用开发平台，融合了后端即服务（Backend as Service）和 LLMOps 的理念，使开发者可以快速搭建生产级的生成式 AI 应用。即使你是非技术人员，也能参与到 AI 应用的定义和数据运营过程中。

Dify 内置了构建 LLM 应用所需的关键技术栈，包括对数百个模型的支持、直观的 Prompt 编排界面、高质量的 RAG 引擎、稳健的 Agent 框架、灵活的流程编排，并同时提供了一套易用的界面和 API。这为开发者节省了许多重复造轮子的时间，使其可以专注于创新和业务需求。

你或许可以把 LangChain 这类的开发库（Library）想象为有着锤子、钉子的工具箱。与之相比，Dify 提供了更接近生产需要的完整方案，Dify 好比是一套脚手架，并且经过了精良的工程设计和软件测试。重要的是，Dify 是开源的，它由一个专业的全职团队和社区共同打造。你可以基于任何模型自部署类似 Assistants API 和 GPTs 的能力，在灵活和安全的基础上，同时保持对数据的完全控制。社区用户对 Dify 的产品评价可以归结为简单、克制、迭代迅速。

Dify 一词源自 Define + Modify，意指定义并且持续改进你的 AI 应用，它是为你而做的（Do it for you）。Dify 能做什么呢？它可以帮助创业者快速将 AI 应用创意变成现实，无论成功和失败都需要加速。在真实世界，已经有几十个团队通过 Dify 构建 MVP（最小可用产品）获得投资，或通过 POC（概念验证）赢得了客户的订单。此外，Dify 还可以将 LLM 集成至已有业务，通过引入 LLM 增强现有应用的能力，接入 Dify 的 RESTful API 从而实现 Prompt 与业务代码的解耦，在 Dify 的管理界面跟踪数据、成本和用量，持续改进应用效果。作为企业级 LLM 基础设施，一些银行和大型互联网公司正在将 Dify 部署为企业内的 LLM 网关，加速 GenAI 技术在企业内的推广，并实现中心化的监管。对于技术爱好者来说，Dify 也是探索 LLM 能力边界的利器，即使在 GPTs 推出以前，就已经有超过 60,000 开发者在 Dify 上创建了自己的第一个应用。



2. 实验目标

1. 掌握Dify平台的基本功能和操作流程。
2. 学会接入大模型并构建AI应用。
3. 理解工作流、知识库、工具、发布等功能的使用。

4. 探索Dify的扩展、协同和管理功能，提升团队协作效率。

3. 实验环境


- 准备工作：进入Dify平台

4. 实验任务

任务1：接入大模型

Dify 是基于大语言模型的 AI 应用开发平台，初次使用时你需要先在 Dify 的 **设置 -- 模型供应商** 页面内添加并配置所需要的模型。





例如我选择的是OpenAI的API,我需要输入API KEY以及网址。

设置 OpenAI

API Key *

sk-eUs*****B0

组织 ID

123456

API Base

https://free.v36.cm

从 OpenAI 获取 API Key [🔗](#)

移除

取消

保存

🔒 您的密钥将使用 **PKCS1_OAEP** 技术进行加密和存储。

模型类型

在 Dify 中，我们按模型的使用场景将模型分为以下 4 类：

1. **系统推理模型**。在创建的应用中，用的是该类型的模型。智聊、对话名称生成、下一步问题建议用的也是推理模型。

已支持的系统推理模型供应商：[OpenAI](#)、[Azure OpenAI Service](#)、[Anthropic](#)、Hugging Face Hub、Replicate、Xinference、OpenLLM、[讯飞星火](#)、[文心一言](#)、[通义千问](#)、[Minimax](#)、ZHIPU(ChatGLM)

2. **Embedding 模型**。在知识库中，将分段过的文档做 Embedding 用的是该类型的模型。在使用了知识库的应用中，将用户的提问做 Embedding 处理也是用的该类型的模型。

已支持的 Embedding 模型供应商：OpenAI、ZHIPU(ChatGLM)、Jina AI([Jina Embeddings](#))

3. **Rerank 模型**。Rerank 模型用于增强检索能力，改善 LLM 的搜索结果。


已支持的 Rerank 模型供应商：Cohere、Jina AI([Jina Reranker](#))

4. **语音转文字模型**。将对话型应用中，将语音转文字用的是该类型的模型。

已支持的语音转文字模型供应商：OpenAI


设置默认模型

Dify 在需要模型时，会根据使用场景来选择设置过的默认模型。在 [设置 > 模型供应商](#) 中设置默认模型。



使用模型

配置完模型后，就可以在应用中使用这些模型了：



任务2：构建应用

在 Dify 中，一个“应用”是指基于 GPT 等大语言模型构建的实际场景应用。通过创建应用，你可以将智能 AI 技术应用于特定的需求。它既包含了开发 AI 应用的工程范式，也包含了具体的交付物。

简而言之，一个应用为开发者交付了：

- 封装友好的 API，可由后端或前端应用直接调用，通过 Token 鉴权
- 开箱即用、美观且托管的 WebApp，你可以 WebApp 的模板进行二次开发
- 一套包含提示词工程、上下文管理、日志分析和标注的易用界面

你可以任选**其中之一**或**全部**，来支撑你的 AI 应用开发。

应用类型

Dify 中提供了五种应用类型：

- **聊天助手**：基于 LLM 构建对话式交互的助手
- **文本生成应用**：面向文本生成类任务的助手，例如撰写故事、文本分类、翻译等
- **Agent**：能够分解任务、推理思考、调用工具的对话式智能助手
- **对话流**：适用于定义等复杂流程的多轮对话场景，具有记忆功能的应用编排方式
- **工作流**：适用于自动化、批处理等单轮生成类任务的场景的应用编排方式

文本生成应用与聊天助手的区别见下表：

文本生成应用		聊天助手
WebApp 界面	表单+结果式	聊天式
WebAPI 端点	completion-messages	chat-messages
交互方式	一问一答	多轮对话
流式结果返回	支持	支持
上下文保存	当次	持续
用户输入表单	支持	支持
知识库与插件	支持	支持
AI 开场白	不支持	支持
情景举例	翻译、判断、索引	聊天

4.2.1 创建应用

你可以通过 3 种方式在 Dify 的工作室内创建应用：

- 基于应用模板创建（新手推荐）
- 创建一个空白应用
- 通过 DSL 文件（本地/在线）创建应用


1、从模板创建应用

初次使用 Dify 时，你可能对于应用创建比较陌生。为了帮助新手用户快速了解在 Dify 上能够构建哪些类型的应用，Dify 团队内的提示词工程师已经创建好了多场景、高质量的应用模板。

你可以从导航选择「工作室」，在应用列表内选择「从模板创建」。




会出现多个应用模版供用户使用，任意选择某个模板，并将其添加至工作区。




2、创建一个新应用

如果你需要在 Dify 上创建一个空白应用，你可以从导航选择「工作室」，在应用列表内选择「从空白创建」。



创建应用时，你需要给应用起一个名字、选择合适的图标，或者上传喜爱的图片用作图标、使用一段清晰的文字描述此应用的用途，以便后续应用在团队内的使用。



3、通过 DSL 文件创建应用

注意：Dify DSL 是由 Dify.AI 所定义的 AI 应用工程文件标准，文件格式为 YML。该标准涵盖应用在 Dify 内的基本描述、模型参数、编排配置等信息。

本地导入


如果你从社区或其它人那里获得了一个应用模板（DSL 文件），可以从工作室选择「导入 DSL 文件」。DSL 文件导入后将直接加载原应用的所有配置信息。



URL 导入

你也可以通过 URL 导入 DSL 文件，参考的链接格式：

```
https://example.com/your_dsl.yml
```



4.2.2 聊天助手

对话型应用采用一问一答模式与用户持续对话。

适用场景

对话型应用可以用在客户服务、在线教育、医疗保健、金融服务等领域。这些应用可以帮助组织提高工作效率、减少人工成本和提供更好的用户体验。

如何编排


对话型应用的编排支持：对话前提示词，变量，上下文，开场白和下一步问题建议。

下面边以做一个 **面试官** 的应用为例来介绍编排对话型应用。

接下来让我们创建一个聊天助手来体验一下。


1、创建应用

在首页点击“创建应用”按钮创建应用。填上应用名称，应用类型选择**聊天助手**。



2、编排应用

创建应用后会自动跳转到应用概览页。点击左侧菜单 **编排** 来编排应用。




填写提示词

提示词用于约束 AI 给出专业的回复，让回应更加精确。你可以借助内置的提示生成器，编写合适的提示词。提示词内支持插入表单变量，例如 `{{input}}`。提示词中的变量的值会替换成用户填写的值。


示例：

1. 输入提示指令，要求给出一段面试场景的提示词。
2. 右侧内容框将自动生成提示词。
3. 你可以在提示词内插入自定义变量。




添加上下文

如果想要让 AI 的对话范围局限在[知识库](#)内，例如企业内的客服话术规范，可以在“上下文”内引用知识库。



发布应用

调试好应用后，点击右上角的“发布”按钮生成独立的 AI 应用。除了通过公开 URL 体验该应用，你也进行基于 APIs 的二次开发、嵌入至网站内等操作。




4.2.3 Agent

定义


智能助手（Agent Assistant），利用大语言模型的推理能力，能够自主对复杂的人类任务进行目标规划、任务拆解、工具调用、过程迭代，并在没有人类干预的情况下完成任务。

如何使用智能助手

为了方便快速上手使用，你可以在“探索”中找到智能助手的应用模板，添加到自己的工作区，或者在此基础上进行自定义。在全新的 Dify 工作室中，你也可以从零编排一个专属于你自己的智能助手，帮助你完成财务报表分析、撰写报告、Logo 设计、旅程规划等任务。



选择智能助手的推理模型，智能助手的任务完成能力取决于模型推理能力，我们建议在使用智能助手时选择推理能力更强的模型系列如 gpt-4 以获得更稳定的任务完成效果。




你可以在“提示词”中编写智能助手的指令，为了能够达到更优的预期效果，你可以在指令中明确它的任务目标、工作流程、资源和限制等。

添加助手需要的工具

在“上下文”中，你可以添加智能助手可以用于查询的知识库工具，这将帮助它获取外部背景知识。

在“工具”中，你可以添加需要使用的工具。工具可以扩展 LLM 的能力，比如联网搜索、科学计算或绘制图片，赋予并增强了 LLM 连接外部世界的能力。Dify 提供了两种工具类型：**第一方工具**和**自定义工具**。

你可以直接使用 Dify 生态提供的第一方内置工具，或者轻松导入自定义的 API 工具（目前支持 OpenAPI / Swagger 和 OpenAI Plugin 规范）。



“工具”功能允许用户借助外部能力，在 Dify 上创建出更加强大的 AI 应用。例如你可以为智能助理型应用（Agent）编排合适的工具，它可以通过任务推理、步骤拆解、调用工具完成复杂任务。


另外工具也可以方便将你的应用与其他系统或服务连接，与外部环境交互。例如代码执行、对专属信息源的访问等。你只需要在对话框中谈及需要调用的某个工具的名字，即可自动调用该工具。



配置 Agent


在 Dify 上为智能助手提供了 Function calling（函数调用）和 ReAct 两种推理模式。已支持 Function Call 的模型系列如 gpt-3.5/gpt-4 拥有效果更佳、更稳定的表现，尚未支持 Function calling 的模型系列，支持了 ReAct 推理框架实现类似的效果。

在 Agent 配置中，你可以修改助手的迭代次数限制。



配置对话开场白


你可以为智能助手配置一套会话开场白和开场问题，配置的对话开场白将在每次用户初次对话中展示助手可以完成什么样的任务，以及可以提出的问题示例。



添加文件上传


部分多模态 LLM 已原生支持处理文件，例如 [Claude 3.5 Sonnet](#) 或 [Gemini 1.5 Pro](#)。你可以在 LLM 的官方网站了解文件上传能力的支持情况。

选择具备读取文件的 LLM，开启“文档”功能。无需复杂配置即可让当前 Chatbot 具备文件识别能力。



调试与预览

编排完智能助手之后，你可以在发布成应用之前进行调试与预览，查看助手的任务完成效果。



最后将应用发布。


任务3：工作流

基本介绍

工作流通过将复杂的任务分解成较小的步骤（节点）降低系统复杂度，减少了对提示词技术和模型推理能力的依赖，提高了 LLM 应用面向复杂任务的性能，提升了系统的可解释性、稳定性和容错性。

Dify 工作流分为两种类型：

- **Chatflow**：面向对话类情景，包括客户服务、语义搜索、以及其他需要在构建响应时进行多步逻辑的对话式应用程序。
- **Workflow**：面向自动化和批处理情景，适合高质量翻译、数据分析、内容生成、电子邮件自动化等应用程序。



为解决自然语言输入中用户意图识别的复杂性，Chatflow 提供了问题理解类节点。相对于 Workflow 增加了 Chatbot 特性的支持，如：对话历史（Memory）、标注回复、Answer 节点等。


为解决自动化和批处理情景中复杂业务逻辑，工作流提供了丰富的逻辑节点，如代码节点、IF/ELSE 节点、模板转换、迭代节点等，除此之外也将提供定时和事件触发的能力，方便构建自动化流程。

核心节点


- **开始 (Start)**：定义工作流启动的初始参数。
- **结束 (End)**：定义工作流结束的最终输出内容。
- **大语言模型 (LLM)**：调用大语言模型处理自然语言任务。
- **知识检索 (Knowledge Retrieval)**：从知识库中检索与用户问题相关的文本内容。
- **条件分支 (IF/ELSE)**：根据条件判断将流程拆分为两个分支。
- **代码执行 (Code)**：运行 Python/NodeJS 代码实现自定义逻辑。
- **HTTP 请求 (HTTP Request)**：通过 HTTP 协议发送请求，获取外部数据。

假如我们要搭建一个中医问诊助手，可以按照以下方式创建一个简单的工作流

首先创建一个工作流，名字叫做问诊大师。



接下来我们选择LLM节点



我们在开始节点创建一个变量作为用户疾病的输入。

添加变量

字段类型



文本



段落



下拉选项



数字



单文件



文件列表

变量名称

inupt

显示名称

inupt

最大长度

48



必填

取消

保存

接着在LLM节点设置接受的变量。



再给大模型一个提示词，让大模型知道需要哪些参数，以及他自己的身份。

上下文 ?

开始 / input String

要启用上下文功能，请在提示中填写上下文变量。

SYSTEM ? 319

Jinja

{x}




你现在是中医问诊大师，您的任务是根据用户提供的症状、体征或健康问题进行分析和回答。请遵循以下步骤完成任务：

1. 仔细阅读用户输入的内容，理解他们所描述的症状或健康问题。
2. 根据中医理论，分析用户的症状，考虑可能的病因和相关的中医概念，如阴阳、五行、脏腑等。
3. 提供针对用户症状的建议，包括可能的中医治疗方法、草药、饮食建议或生活方式调整。
4. 确保您的回答清晰、简洁，并且不包含任何XML标签。
5. 如果适用，可以提供一些常见的中医术语的解释，以帮助用户更好地理解您的建议。用户输入为：

开始 / {x} input

+ 添加消息

最后发布应用试试效果



任务4：知识库

知识库功能将 [RAG 管线](#)上的各环节可视化，提供了一套简单易用的用户界面来方便应用构建者管理个人或者团队的知识库，并能够快速集成至 AI 应用中。

开发者可以将企业内部文档、FAQ、规范信息等内容上传至知识库进行结构化处理，供后续 LLM 查询。

相比于 AI 大模型内置的静态预训练数据，知识库中的内容能够实时更新，确保 LLM 可以访问到最新的信息，避免因信息过时或遗漏而产生的问题。

LLM 接收到用户的问题后，将首先基于关键词在知识库内检索内容。知识库将根据关键词，召回相关度排名较高的内容区块，向 LLM 提供关键上下文以辅助其生成更加精准的回答。

开发者可以通过此方式确保 LLM 不仅仅依赖于训练数据中的知识，还能够处理来自实时文档和数据库的动态数据，从而提高回答的准确性和相关性。

核心优势：

- **实时性**：知识库中的数据可随时更新，确保模型获得最新的上下文。
- **精准性**：通过检索相关文档，LLM 能够基于实际内容生成高质量的回答，减少幻觉现象。
- **灵活性**：开发者可自定义知识库内容，根据实际需求调整知识的覆盖范围。

准备文本文件，例如：

- 长文本内容（TXT、Markdown、DOCX、HTML、JSON 甚至是 PDF）
- 结构化数据（CSV、Excel 等）
- 在线数据源（网页爬虫、Notion 等）

将文件上传至“知识库”即可自动完成数据处理。

创建知识库

轻点 Dify 平台顶部导航中“**知识库**”→“**创建知识库**”。你可以通过上传本地文件或导入在线数据两种方式上传文档至知识库内。



上传本地文件

拖拽或选中文件进行上传，**支持批量上传**，同时上传的文件数量限制取决于[订阅计划](#)。

本地上传文档文件存在以下限制：

- 单文档的上传大小限制为 **15MB**
- 不同 SaaS 版本的[订阅计划](#)限定了**批量上传个数、文档上传总数、向量存储空间**

导入在线数据

创建知识库时支持通过在线数据导入。知识库支持导入以下两种在线数据：

- ## 1、从 Notion 导入数据

- ## 2、从网页导入数据

引用在线数据的知识库后续无法新增本地文档,也无法变更为本地文件类型的知识库,以防止单一知识库存在多种数据来源而造成管理困难。

指定分段模式

知识库支持两种分段模式：**通用模式**与**父子模式**。如果你是首次创建知识库，建议选择父子模式。

通用

通用文本分块模式，检索和召回的块是相同的

分段标识符^①

\n\n

分段最大长度

500

tokens

⬆️⬇️⬆️

分段重叠长度^②

50

tokens

⬆️⬇️⬆️

文本预处理规则

☒ 替换掉连续的空格、换行符和制表符

☐ 删除所有 URL 和电子邮件地址

☐ 使用 Q&A 分段，语言 Chinese^③

预览块

重置



父子分段

使用父子模式时，子块用于检索，父块用作上下文

父块用作上下文



段落

此模式根据分隔符和最大块长度将文本拆分为段落，使用拆分文本作为检索的父块

分段标识符 ^①

分段最大长度

tokens

^

v



全文

整个文档用作父块并直接检索。请注意，出于性能原因，超过10000个标记的文本将被自动截断。



子块用于检索

分段标识符 ^①

分段最大长度

tokens

^

v

文本预处理规则

☒ 替换掉连续的空格、换行符和制表符

☐ 删除所有 URL 和电子邮件地址



预览块

重置

设定索引方法

正如搜索引擎通过高效的索引算法匹配与用户问题最相关的网页内容，索引方式是否合理将直接影响 LLM 对知识库内容的检索效率以及回答的准确性。

提供“高质量”与“经济”两种索引方法，其中分别提供不同的检索设置选项：

高质量

在高质量模式下，使用 Embedding 嵌入模型将已分段的文本块转换为数字向量，帮助更加有效地压缩与存储大量文本信息；**使得用户问题与文本之间的匹配能够更加精准。**

将内容块向量化并录入至数据库后，需要通过有效的检索方式调取与用户问题相匹配的内容块。高质量模式提供向量检索、全文检索和混合检索三种检索设置。

选择高质量模式后，当前知识库的索引方式无法在后续降级为 **“经济”索引模式**。如需切换，建议重新创建知识库并重选索引方式。

索引方式



高质量 推荐

调用嵌入模型处理文档以实现更精确的检索，可以帮助LLM生成高质量的答案。

经济

在经济模式下，每个区块内使用 10 个关键词进行检索，降低了准确度但无需产生费用。对于检索到的区块，仅提供倒排索引方式选择最相关的区块。

选择经济型索引方式后，若感觉实际的效果不佳，可以在知识库设置页中升级为 **“高质量”索引方式**。



经济

每个数据块使用10个关键词进行检索，不会消耗任何tokens，但会以降低检索准确性为代价。

指定检索方式

知识库在接收到用户查询问题后，按照预设的检索方式在已有的文档内查找相关内容，提取出高度相关的信息片段供语言模型生成高质量答案。这将决定 LLM 所能获取的背景信息，从而影响生成结果的准确性和可信度。

常见的检索方式包括基于向量相似度的语义检索，以及基于关键词的精准匹配：前者将文本内容块和问题查询转化为向量，通过计算向量相似度匹配更深层次的语义关联；后者通过倒排索引，即搜索引擎常用的检索方法，匹配问题与关键内容。

不同的索引方法对应差异化的检索设置。

高质量索引

在高质量索引方式下，Dify 提供向量检索、全文检索与混合检索设置：

向量检索

定义： 向量化用户输入的问题并生成查询文本的数学向量，比较查询向量与知识库内对应的文本向量间的距离，寻找相邻的分段内容。

全文检索

定义： 关键词检索，即索引文档中的所有词汇。用户输入问题后，通过明文关键词匹配知识库内对应的文本片段，返回符合关键词的文本片段；类似搜索引擎中的明文检索。

混合检索

定义： 同时执行全文检索和向量检索，或 Rerank 模型，从查询结果中选择匹配用户问题的最佳结果。

检索设置

了解更多关于检索方法，您可以随时在知识库设置中更改此设置。

向量检索

通过生成查询嵌入并查询与其向量表示最相似的文本分段

Rerank 模型

Top K

3

Score 阈值

0.5

全文检索

索引文档中的所有词汇，从而允许用户查询任意词汇，并返回包含这些词汇的文本片段

混合检索

同时执行全文检索和向量检索，并应用重排序步骤，从两类查询结果中选择匹配用户问题的最佳结果，用户可以选择设置权重或配置重新排序模型。

经济索引

倒排索引

在经济索引方式下，仅提供**倒排索引方式**。这是一种用于快速检索文档中关键词的索引结构，常用于在线搜索引擎。倒排索引仅支持 **TopK** 设置项。

倒排索引

倒排索引是一种用于高效检索的结构。按术语组织，每个术语指向包含它的文档或网页

Top K

3

案例体验5：搭建一个中医问诊助手

知识库的概念

大语言模型的训练数据一般基于公开的数据，它的训练数据有多个互联网文本语料库，覆盖线上书籍、新闻、文章、科学论文、维基百科、社交媒体帖子等等海量的文本。大语言模型每一次训练需要消耗大量算力，这意味着模型的知识一般不会包含私有领域的知识，同时在公开知识领域存在一定的滞后性。

举个例子，目前流行的企业客服智能机器人，它能够回答企业销售的产品问题。这就是知识库的应用。因为如果没有知识库，大语言模型能够回答企业销售的产品问题吗？显然是不能的，因为这些资料都是企业私有的，而大语言模型并没有提前学习这部分私有知识。

为了解决这一问题，目前通用的方案是采用 **RAG**（检索增强生成）技术，使用用户问题来匹配最相关的外部数据，将检索到的相关内容召回后作为模型提示词的上下文来重新组织回复。

RAG流程

```
graph LR; Q[Standalone Question] --> LLM((LLM)); Q --> VS[(Vectorstore)]; VS --> R[Relevant Documents]; R --> LLM; LLM --> A[Answer]
```

该图展示了RAG（检索增强生成）流程。一个“Standalone Question”（独立问题）输入到“LLM”（大语言模型）中，同时也会输入到“Vectorstore”（向量存储库）中。Vectorstore 会返回相关的文档片段（Relevant Documents），这些片段会被输入到 LLM 中，最终生成“Answer”（答案）。

知识库处理

分段和清洗

分段设置

通用

通用文本分块模式。检索和召回的块是相同的

分段标识符 ^①

分段最大长度

分段重叠长度 ^①

\n\n

500

tokens

^

v

50

tokens

^

v

文本预处理规则

☒ 替换掉连续的空格、换行符和制表符

☐ 删除所有 URL 和电子邮件地址

☐ 使用 Q&A 分段, 语言

Chinese

^①

预览块

重置

索引

索引方式

高质量

推荐

调用嵌入模型处理文档以实现更精确的检索, 可以帮助LLM生成高质量的答案。

经济

每个数据块使用10个关键词进行检索, 不会消耗任何tokens, 但会以降低检索准确性为代价。

使用高质量模式进行嵌入后, 无法切换回经济模式。

Embedding 模型

text-embedding-3-large

v

检索设置

检索设置

了解更多关于检索方法, 您可以随时在知识库设置中更改此设置。

向量检索

通过生成查询嵌入并查询与其向量表示最相似的文本分段

全文检索

索引文档中的所有词汇, 从而允许用户查询任意词汇, 并返回包含这些词汇的文本片段

混合检索

推荐

同时执行全文检索和向量检索, 并应用重排序步骤, 从两类查询结果中选择匹配用户问题的最佳结果, 用户可以选择设置权重或配置重新排序模型。

权重设置

通过调整分配的权重, 重新排序策略确定是优先进行语义匹配还是关键字匹配。

Rerank 模型

重排序模型将根据候选文档列表与用户问题语义匹配度进行重新排序, 从而改进语义排序的结果

语义 0.7

0.3 关键词

Top K ^①

3

^

v

Score 阈值 ^②


0.5

^

v

创建 workflow

开始设置一个变量作为用户的输入, 之后添加一个LLM用来提取用户问题的关键字, 接着检索知识库, 在创建一个LLM用来回答知识库中的内容。



Test Run#8

输入 结果 详情 追踪

>

开始

64.981 ms

✓

>

LLM

162 tokens · 5.036 s

✓

▼

知识检索

98.232 ms

✓

输入

```
1 {
2   "query": "舌色是指舌头的颜色，它在中医诊断中
   被用来观察身体的健康状况。舌色可以反映出身体
   内部的状况，如气血、脏腑功能等。常见的舌色包
   括红色、淡红色、苍白色、紫色、黄色等，每种颜
   色可能对应不同的健康问题。"
3 }
```

输出

	常舌色红，甚至呈鲜红色 血(阴分) 舌体不小，舌红，有苔—实热证(气分热甚；脏腑阳热亢盛) \n 红舌 较正常舌色红，甚至呈鲜红色 血(阴分) 舌体小，舌鲜红少苔，或有裂纹，或红光无苔—阴虚证 \n 绛舌 较红舌颜色更深，或略带暗红色 血(阴分) 舌绛有苔—里热亢盛证(温热病营血热盛；脏腑内热炽盛) \n 绛舌 "
--	--

>

LLM 2

1.843K tokens · 11.631 s

✓

▼

结束

10.304 ms

✓

可以看到是根据知识库中的内容回答的。以上设置可根据实际情况来调整。

5. 实验结果

完成上述任务后，用户将：

- 成功接入大模型并构建一个功能完整的AI应用。
- 掌握工作流、知识库、工具等高级功能的使用。
- 实现应用的发布、监测和优化。
- 学会团队协作和项目管理的基本操作。

6. 实验总结

通过本实验，用户能够全面了解Dify平台的功能和应用场景，为后续开发更复杂的AI应用奠定基础。建议用户进一步探索Dify的API接口和社区资源，以实现更高级的定制化开发。